Metacognitia unui Agent Psihiatric AI antrenat prin Confesii care oferă Diagnostice

Apetrei Ștefan – Lucian (stefan-lucian.apetrei93@s.fpse.unibuc.ro)
Department of Psychology Cognitive Science, UNIBUC

Abstract

Metacogniția conform lui John Flavell, este definită ca și cunoașterea despre cogniție și controlul acesteia. Metacogniția are două componeente principale: monitorizarea (observarea propriilor procese) și control (reglarea lor). Un LLM Conversațional se bazeză pe Big Data-ul pe care este antrenat și răspunde la nivel statistic. El funcționează fundamental pe baze probabilistice, optimizând predicția următorului token pentru a maximiza plauzibilitatea lingvistică, adesea în detrimentul acurateței factuale. Acest proces este echivalent cu o cogniție rapidă și automată (Dehaene), dar lipsită de mecanisme interne de verificare, ceea ce predispune modelul la halucinații. Vom numi în lucrare acesta versiune de LLM (precum GPT-5, Gemini-3, Claude Opus 4.5, etc.) ca Agent A.

În contrast acest proiect propune implementarea unei arhitecturi metacognitive cu ajutorul metodologiei realizate pe cadrul modelului GPT-5, "Training LLMs for Honesty via Confessions, Joglekar et al., 2025". Implementarea se va realiza prin folosirea unui mechanism de auto-evaluarea, denumit "raport de confesiune", unui sistem de baze vectoriale, se va folosi de Chain-of-Thought, si va fi reprezenta un chatbot pe sistem RAG. Vom numi această versiune augmentată Agent B. Spre deosebire de A, B nu finalizează acest process de generare a răspunsului imediat, ci sistemul declanșează o secvență secundară de procesare – echivalentul monitorizării cognitive, prin solocitarea unui raport structurat (JSON). Conform metodologiei Joglekar et al. (2025), acest raport impune lui B să: a) Enumere explicit toate constrângerile și obiectivele derivate din prompt-ul initial (informațiile din DSM-5, și interdicția de diagnoastica), b) Analizeze critic măsura în care răspunsul generat a respectat instrucțiunile și c) Raporteze zonele de incertitudine subiectivă sau ambiguitate.

Inovația centrală a acestei metodologii rezidă în separarea semnalului de recompensă: evaluarea confesiunii se bazează exclusiv pe onestitatea sa și nu influențează scorul primit pentru răspunsul inițial. Această decuplare creează un mediu în care „calea minimei rezistențe" pentru maximizarea recompensei este recunoașterea erorii, mai degrabă decât disimularea ei. În cadrul acestui proiect, confesiunea funcționează ca un mecanism de control metacognitiv: dacă raportul JSON indică o neconformitate cu criteriile DSM-5 sau o incertitudine ridicată, sistemul intervine automat prin blocarea răspunsului neconform. Studiul urmărește să demonstreze că Agentul B atinge un nivel superior de siguranță și fidelitate clinică, validând confesiunea ca un instrument viabil pentru reducerea halucinațiilor în sistemele critice de inteligență artificială

Keywords: AI, CHATGPT, GPT-5, Metacognition, Cognitive Science, LLM, Token, RAG, Embeddings, Knowledge, DSM-5, Disorders

References

Manas Joglekar et., al. (2025). Training LLM's for Honesty https://cdn.openai.com/pdf/6216f8bc-187b-4bbb-8932-ba7c40c5553d/confessions_paper.pdf

John N. Flavell (1979). Metacognition and Cognitive Monitoring https://jgregorymcverry.com/readings/flavell1979MetacognitionAndCogntiveMonitoring.pdf